Կեղծ լուրերի հայտնաբերման և ճշգրտման ավտոմատացված համակարգի մշակում

Գործնական մաս և փորձարարական արդյունքներ

Հետազոտական իրականացում անգլերեն տվյալներով

1 Իրականացված համակարգը

Իրականացվել է վերարտադրվող հետազոտական համակարգ՝ երկու տեքստային դասակարգիչով, աղբյուրների որոնմամբ, ապացույց–պնդում իմաստային համեմատությամբ և աղբյուրից վերցված ուղղման առաջարկով։ Ծրագիրն ունի հայերեն տեղային միջերես, իսկ մուտքային տեքստերը և ուսուցման տվյալներն անգլերեն են։ LIAR-ը օգտագործվում է անգլերեն պնդումների վեցաստիճան դասակարգման, FakeNewsNet-ը՝ անգլերեն վերնագրերի fake/real դասակարգման համար։ Այս խնդիրներն ունեն տարբեր դասեր և բարդություն, ուստի դրանց տոկոսները ուղղակի համեմատելի չեն։

2 Տվյալների նախնական մշակում

Կիրառվում են Unicode NFKC նորմալացում, HTML նշագրերի հեռացում, HTML entity-ների փոխակերպում, URL-ի ընդհանուր նշիչ, փոքրատառերի փոխակերպում և բացատների կարգավորում։ Թվերը և ժխտումը պահպանվում են։ Stopword-ների հեռացում և լեմատացում չեն կիրառվել։ Պիտակների հակասող օրինակները հեռացվում են, կրկնվող նորմալացված տեքստից պահպանվում է մեկ օրինակ։

Հավաքածու	Հում	Հակասող	Կրկնվող	Մնացած	Train / Valid / Test
liar	12 791	16	24	12 751	10 212 / 1277 / 1262
fakenewsnet	23 196	369	1239	21 588	15 111 / 3238 / 3239

LIAR-ում պահպանված են պաշտոնական բաժանումները՝ մաքրումից հետո։ FakeNewsNet-ի բաժանումը 70/15/15 է՝ seed=42, աղբյուրի և դասի համատեղ շերտավորմամբ։ Բաժանումների միջև նորմալացված ճշգրիտ տեքստային համընկնումների թիվը 0 է։ Տվյալների ամբողջության վրա նախնական հակասությունների մաքրումը փոխում է գնահատվող պոպուլյացիան։ Թեմատիկ կամ մոտ իմաստային կրկնությունները ամբողջությամբ չեն բացառվել։

3 Հատկանիշների դուրս բերում

Օգտագործվում է TF-IDF՝ մեկ և երկու բառից կազմված n-gram-ներով, min_df=2, max_df=0.98, առավելագույնը 60,000 հատկանիշ և sublinear_tf=True։ Բառապաշարը և IDF կշիռները հաշվարկվում են միայն ուսուցման հավաքածուից։ Գնահատման

տվյալները չեն մասնակցում հատկանիշների ուսուցմանը: URL-ները, աղբյուրի անունը և LIAR-ի պիտակից կախված խոսնակի հաշվիչները մոդելի մուտք չեն:

4 Մոդելների իրականացում

Համեմատվել են majority baseline, Complement Naive Bayes, Logistic Regression և Linear SVM մոդելները: Երկու վերջիններում կիրառվում է դասերի հավասարակշռված կշռում: Ընտրության միակ չափանիշը validation macro-F1-ն է: Ընտրված մոդելը պահպանվում է joblib ձևաչափով և օգտագործվում է FastAPI ծառայությունում:

liar validation արդյունքներ

Մոդել	Accuracy	Macro-F1
Logistic Regression	25.76%	25.96%
Linear SVM	24.67%	24.90%
Complement NB	25.14%	24.88%
majority	19.42%	5.42%

fakenewsnet validation արդյունքներ

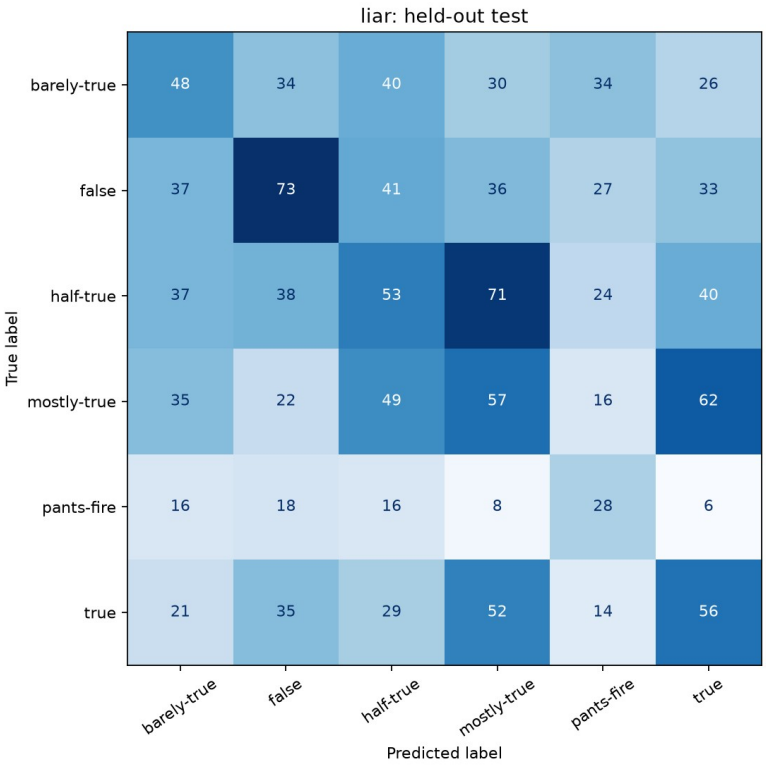
Մոդել	Accuracy	Macro-F1
Logistic Regression	82.00%	76.88%
Complement NB	82.95%	76.36%
Linear SVM	81.90%	76.21%
majority	75.94%	43.16%

5 Անկախ թեստային գնահատում

Հավաքածու	Accuracy	Macro precision	Macro recall	Macro-F1
liar	24.96%	24.72%	25.58%	24.90%
fakenewsnet	82.37%	75.91%	77.91%	76.79%

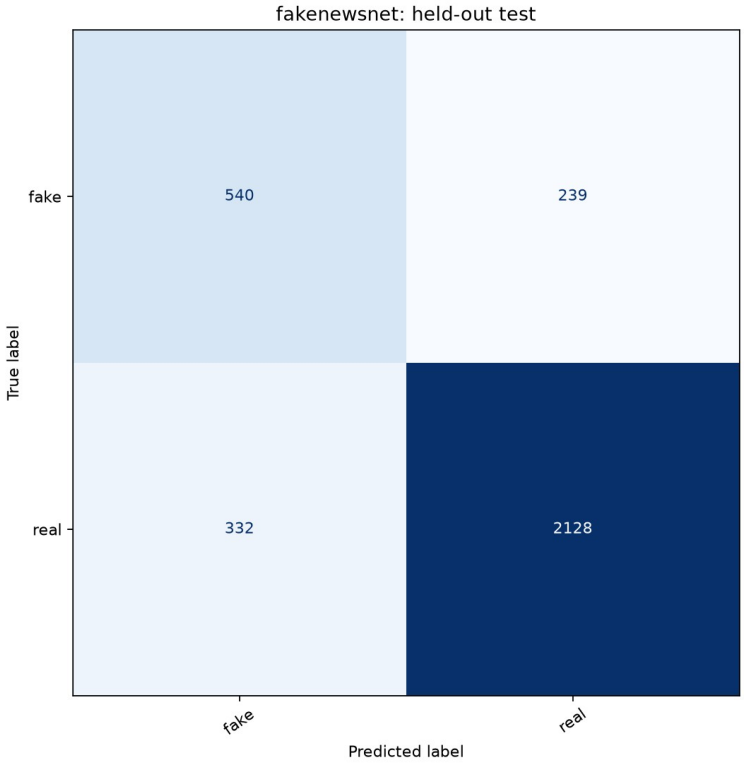
F1-ը precision-ի և recall-ի հարմոնիկ միջինն է: Macro-F1-ը դասերի F1-երի չկշռված միջինն է և ընտրվել է որպես հիմնական չափանիշ՝ դասերի անհավասարակշռությունը հաշվի առնելու համար:

liar: Macro-F1-ի 95% bootstrap միջակայքը՝ 22.40%–27.14% (500 վերանմուշառում, seed=42):



Նկար 1 LIAR թեստային շփոթության մատրից

fakenewsnet: Macro-F1-ի 95% bootstrap միջակայքը՝ 74.98%–78.48% (500 վերանմուշառում, seed=42):



Նկար 2 FakeNewsNet թեստային շփոթության մատրից

Աղբյուրների միջև տեղափոխում

Ուսուցման աղբյուր → թեստի աղբյուր	Accuracy	Macro-F1
gossipcop_to_politifact	57.82%	52.05%
politifact_to_gossipcop	47.25%	45.55%

Այս փորձը ցույց է տալիս աղբյուրի փոփոխության նկատմամբ զգայունություն: Այն օգտագործում է ընտրված մոդելի նույն կառուցվածքը՝ վերաուսուցված միայն սկզբնական train-ի համապատասխան աղբյուրով: Թիրախային test-ը չի օգտագործվում ուսուցման համար: Փոքր PolitiFact ենթաբաժինը սահմանափակում է եզրահանգումների կայունությունը:

6 Ճշգրտում և ապացույցներ

LIAR-ի սկզբնական ֆայլերում փաստաստուգողների հիմնավորումները բացակայում են: Այդ բացը լրացվել է LIAR-PLUS հետազոտական հավելումով: Այն չի փոխարինում սկզբնական տվյալները և չի մասնակցում դասակարգիչների գնահատմանը: 10,242 հում գրառումից ինդեքսավորվել է 10,090-ը: Բացառվել են մաքրված train-ին չհամապատասխանող 30 գրառում, պնդման կամ պիտակի անհամապատասխանությամբ 6 գրառում և անբավարար հիմնավորմամբ 116 գրառում:

Որոնումը համատեղում է բառային TF-IDF կոսինուսային նմանությունը՝ 0.65 կշռով, և նիշային TF-IDF նմանությունը՝ 0.35 կշռով: Ինդեքսավորվում են պնդումները: Յուրաքանչյուր արդյունքին կցված են սկզբնական խոսնակը, համատեքստը, պատմական գնահատականը և փաստաստուգողի հիմնավորման հատվածը: Աղբյուրների հղումները տանում են ամրագրված Git commit-ի տվյալների համապատասխան տողին, ոչ ենթադրված կամ հորինված հոդվածի հասցեին:

Ճշգրիտ համընկնումը վերադարձնում է արխիվային գնահատականն ու հիմնավորումը: Սա պատմական տվյալ է, ոչ այսօրվա ճշմարտության վերահաստատում: Վերաշարադրված կամ փոփոխված պնդման համար ցուցադրվում են առավելագույնը հինգ հարակից նյութեր՝ առանց դրանց գնահատականը նոր պնդմանը վերագրելու: Արխիվային որոնումը ինքնուրույն նոր ուղղված լուր չի գեներացնում. նոր պնդումների ուղղման առանձին մեխանիզմը նկարագրված է ստորև: NASA-ի չորս աղբյուրով օրինակները պահպանվել են որպես նախապես կազմված ուղղման ցուցադրություն:

Որոնման առանձին գնահատում

Փորձարկվել են նախապես կազմված 20 ձեռքով վերաշարադրված հարցումներ՝ հայտնի արխիվային թիրախներով: Հարցումները ինդեքսի ճշգրիտ կրկնություններ չեն: Ճիշտ նյութը առաջին տեղում գտնվել է 16 դեպքում՝ Recall@1 = 80%, առաջին հինգում՝ 20 դեպքում՝ Recall@5 = 100%: MRR@5 = 0.8917: Փորձը փոքր զարգացման հավաքածու է և չի հանդիսանում անկախ իրական աշխարհի փաստաստուգման benchmark: Կշիռները արդյունքներից հետո չեն կարգավորվել:

LIAR test-ի բոլոր 1,262 պնդումները ստուգվել են ինդեքսի ճշգրիտ համընկնման նկատմամբ. համընկնումների թիվը 0 է: Թվերի փոփոխմամբ և ժխտման ավելացմամբ կազմված 60 դեպքերում ավտոմատ ուղղում չի տրվել: Test-ից պատահական ընտրված 50 պնդումների համար նույնպես ուղղում չի ստեղծվել: Այս ստուգումները հաստատում են ձեռնպահ մնալու կանոնը, ոչ փաստային ճշմարտության հայտնաբերման որակը:

Google Fact Check միակցիչը վերադարձնում է հրապարակումների հղումներ և գնահատականներ՝ համապատասխանությունը ստուգելու համար: Այն փորձարկվել է մոդելավորված պատասխաններով, դատարկ կամ սխալ կառուցվածքով տվյալներով և ցանցային խափանումներով: Իրական API բանալիով փորձարկումը բաց է մնում:

Աղբյուրներ՝ https://github.com/Tariq60/LIAR-PLUS և https://aclanthology.org/W18-5513/ : LIAR-PLUS-ը օգտագործվում է հետազոտական նպատակով:

Նոր պնդումների ապացույցներով ստուգում

Իրականացվել է առանձին /verify շղթա՝ մուտքային տեքստի բաժանում պնդումների, աղբյուրների ստացում, համապատասխան հատվածների ընտրություն, բնական լեզվի եզրահանգման NLI մոդելի գնահատում և աղբյուրի նախադասությունից կազմված ուղղում: Մեկ հարցումը ընդունում է մինչև հինգ կարճ պնդում: Բարդ համակցված պնդումների դեպքում պահանջվում է դրանք բաժանել, որպեսզի մեկ մասի ապացույցը չվերագրվի ամբողջ տեքստին:

Սկզբնական աղբյուրների կորպուսը ներառում է NASA-ի տասը փաստագրական էջի պահպանված պատճենները։ Օգտատերը կարող է նշել լրացուցիչ NASA կամ անգլերեն Wikipedia հոդվածի HTTPS հասցե։ Առցանց ռեժիմում MediaWiki որոնումը ստանում է նոր հոդվածների ներածական հատվածները՝ առանց API բանալու։ Պահպանվում են աղբյուրի հասցեն, վերնագիրը, ստացման ժամանակը և տեքստի SHA-256 հեշը։ Wikipedia-ի դեպքում վերադարձվում է կոնկրետ վերանայման հասցեն։

Ապացույցների ընտրությունը սկսվում է պնդման հիմնական առարկայի համընկնումից։ Այնուհետև բառային TF-IDF-ով ընտրվում է առավելագույնը 16 հատված՝ առնվազն 0.14 կոսինուսային նմանությամբ։ Այս շեմերը լեզվական ու թեմատիկ նախնական զտիչներ են, ոչ պնդման ճշմարտության ապացույց։

Իմաստային համեմատությունն իրականացնում է cross-encoder/nli-deberta-v3-small մոդելը։ Այն իր հեղինակների կողմից նախապես ուսուցանվել է SNLI և MultiNLI տվյալներով։ Այս աշխատանքում այդ մոդելը չի վերաուսուցվել LIAR-ի կամ FakeNewsNet-ի վրա։ Մեր տվյալներով իրական ուսուցված մոդելները մնում են նախորդ բաժինների տեքստային դասակարգիչները։ NLI-ի համար օգտագործվում է ամրագրված fa2804872c3b4bd748f38c0185cc85775361e735 վերանայումը։

NLI-ն գնահատում է երեք հարաբերություն՝ հաստատում, հակասություն և չեզոքություն։ Վճռորոշ գնահատականի շեմը 0.92 է։ Սա ճշմարտության 92% հավանականություն չէ. մոդելի ելքերը չեն կալիբրացվել իրական լուրերի հավանականությունների նկատմամբ։ Բարձր հաստատում և բարձր հակասություն միաժամանակ ունենալու դեպքում համակարգը վերադարձնում է հակասող ապացույցների վիճակ։

Հակասության դեպքում առաջարկվող ուղղումը ընտրված աղբյուրի բառացի նախադասությունն է՝ աղբյուրի վերնագրով և հղումով։ Այսպիսով համակարգը կարող է նոր մուտքային պնդման համար ինքնաշխատ կազմել աղբյուրի վրա հիմնված փոխարինող տեքստ՝ առանց ազատ գեներացմամբ նոր փաստ հորինելու։ Բազմապնդում տեքստի ամբողջական ուղղումը տրվում է միայն այն դեպքում, երբ բոլոր մասերի համար կա վճռորոշ գնահատական։ Անորոշ մասի դեպքում ամբողջական վերաշարադրում չի ներկայացվում։

Նոր շղթայի զարգացման և թեստային գնահատում

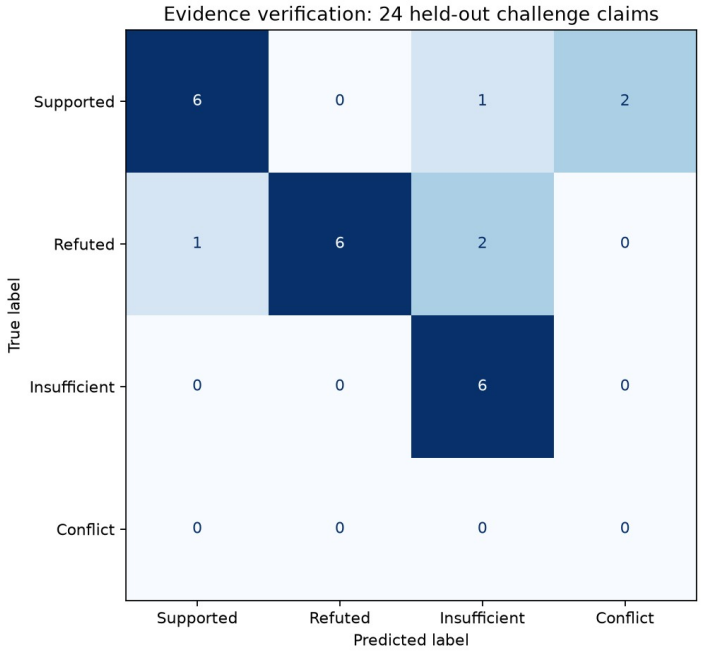
Նախապես կազմվել են 12 զարգացման և 24 թեստային օրինակներ՝ հաստատվող, հերքվող և բավարար ապացույց չունեցող դասերով։ Զարգացման օրինակները վերաբերում են Արեգակին, Երկրին, Լուսնին և Մարսին, իսկ թեստային փաստային օրինակները՝ այլ մոլորակների։ Որոշումներն ու շեմերը ֆիքսվել են զարգացման փուլից հետո։ Թեստի արդյունքները չեն օգտագործվել հաջորդ կարգաբերման համար։

Զարգացման ընթացքում համեմատվել է նաև MiniLM տարբերակը։ Թեմային չառնչվող հատվածների սխալ հակասությունները հանգեցրել են առարկայի նախնական զտիչի ավելացմանը։ Ընտրվել է DeBERTa տարբերակը, որի զարգացման 12 օրինակներից 11-ի ելքը ճիշտ է եղել։

Չափանիշ	Թեստային արդյունք
Օրինակների թիվ	24
Ճիշտ ընդհանուր ելքեր	18 / 24
Accuracy	75.00%
Macro-F1՝ ելքային չորս վիճակներով	58.75%
Առաջարկված ուղղումներ	6
Ճիշտ հերքումներ առաջարկված ուղղումների մեջ	6 / 6
Աղբյուրի բառացի հատվածին համապատասխանություն	6 / 6

Macro-F1-ի հաշվարկում ներառված է նաև կանխատեսված «հակասող ապացույցներ» վիճակը, որի համար այս փոքր հավաքածուում առանձին gold օրինակներ չկան։ Հետևաբար այս չափանիշը չի համեմատվում անմիջապես LIAR-ի կամ FakeNewsNet-ի դասակարգման F1-ի հետ։

Եղել են հինգ ձեռնպահ մնալու կամ հակասության դեպքեր՝ այն օրինակների համար, որտեղ gold գնահատականը վճռորոշ էր, և մեկ սխալ հաստատում՝ Mercury has a moon պնդման համար։ Այդ սխալը պահպանվել է հաշվետվությունում։ Ուղղումների 6/6 արդյունքը վերաբերում է ընդամենը վեց դեպքի և չի նշանակում համընդհանուր 100% ճշգրտություն։ Բառացի համապատասխանությունը հաստատում է աղբյուրի պահպանումը, ոչ ինքնաբերաբար ուղղման իմաստային բավարարությունը։



Նկար 3 Ապացույցներով ստուգում թեստային շփոթության մատրից

Թեստը փոքր, ձեռքով կազմված գիտական և անորոշ պնդումների հավաքածու է, ոչ անկախ լայնածավալ նորությունների benchmark: NLI մոդելը կարող է սխալվել, իսկ աղբյուրները կարող են լինել հնացած կամ անբավարար: Ընդհանուր համակարգի կիրառելիությունը սահմանափակվում է հասանելի և համապատասխան աղբյուրներով:

Իրական առցանց փորձարկում

Իրական MediaWiki հարցումներով փորձարկվել են France's capital city is Berlin և France's capital city is Paris պնդումները: Առաջինի համար համակարգը վերադարձրել է Փարիզը նշող աղբյուրային ուղղում և հոդվածի վերանայման հղումը, երկրորդի համար՝ հաստատող գնահատական: Երկու դեպքում էլ աղբյուրների որոնումն ավարտվել է առանց provider սխալների: Պատասխանների ամբողջ կառուցվածքն ու ժամանակները պահպանված են reports/live_verification.json ֆայլում:

Google Fact Check-ը պահպանված է որպես լրացուցիչ ընտրովի միակցիչ: Դրա իրական բանալիով փորձարկում չի կատարվել: Հիմնական առցանց շղթան աշխատում է առանց այդ միակցիչի՝ արդեն փորձարկված MediaWiki հասանելիությամբ:

7 Ծրագրային ստուգումներ

Անցել են 50 ավտոմատ ստուգումները: Դրանք ընդգրկում են նախնական մաքրումը, կրկնությունների արտահոսքը, accuracy-ի վերահաշվարկը, արխիվի train-only սահմանափակումը, ծառայության մուտքային վավերացումը, չաջակցվող գրային համակարգերը, արտաքին ծառայությունների խափանումներն ու սխալ JSON պատասխանները: Նոր ստուգումները ներառում են թեմային չառնչվող ապացույցների մերժումը, հակասող աղբյուրների դեպքում ձեռնպահ մնալը,

աղբյուրի բառացի պահպանումը և իրական NLI մոդելով նոր ձևակերպման ուղղումը։

Աղբյուրի հասցեների համար թույլատրված են միայն NASA-ի և անգլերեն Wikipedia-ի HTTPS հոդվածները։ Տեղային կամ այլ տիրույթներ, օգտանուն կամ գաղտնաբառ պարունակող URL-ներ և ոչ ստանդարտ պորտեր չեն ընդունվում։ Բրաուզերում ստուգվել են երկու վերլուծական ուղիները, սխալ մուտքերն ու փոքր էկրանի դասավորությունը։ Թեստերի և բրաուզերի արդյունքները պահպանված են reports/tests.log և reports/browser_checks.json ֆայլերում։

8 Եզրակացություններ

Իրականացվել են թեմայի գործնական հիմնական փուլերը՝ տվյալների նախնական մշակում, հատկանիշների դուրս բերում, մոդելների ուսուցում, գնահատում, աղբյուրների որոնում և աղբյուրով հիմնավորված ուղղման առաջարկ։ Դասակարգումը, արխիվային փաստաստուգումը և նոր պնդումների NLI ստուգումը ներկայացված են որպես տարբեր գործողություններ՝ իրենց չափումներով։

FakeNewsNet-ի վերնագրերի դասակարգման արդյունքը 82.37% accuracy և 76.79% macro-F1 է։ LIAR-ի վեց դասով արդյունքը 24.96% accuracy և 24.90% macro-F1 է։ Այս տարբերությունը ցույց է տալիս, որ տեքստային օրինաչափությունների ճանաչումը նույնը չէ, ինչ փաստացի ճշմարտության որոշումը։ Աղբյուրների միջև տեղափոխման դեպքում որակի նվազումը ևս սահմանափակում է ընդհանրացումը։

Նոր պնդումների ստուգման շղթան 24 օրինակով թեստում տվել է 75% ճիշտ ելք։ Այն կարողացել է աղբյուրային ուղղում առաջարկել վեց հերքվող պնդման համար, ինչպես նաև իրական առցանց որոնմամբ մշակել աղբյուրների սկզբնական կորպուսից դուրս օրինակ։ Համակարգը կատարում է ինքնաշխատ, աղբյուրին կապված ուղղման առաջարկ, իսկ անհամապատասխան կամ հակասող ապացույցների դեպքում ձեռնպահ է մնում։

Ստացված իրականացումը հետազոտական համակարգ է՝ սահմանված մուտքերով և գնահատված սահմանափակումներով։ Այն չի երաշխավորում ցանկացած նորության անսխալ ստուգում։ Հայերենը կիրառված է միջերեսում և հաշվետվությունում, իսկ դասակարգումն ու NLI-ն նախատեսված են անգլերենի համար։ Հետագա զարգացումը կարող է ներառել ավելի մեծ անկախ benchmark, հայերեն պիտակավորված տվյալներ, ժամանակային վավերացում և ավելի ճշգրիտ իմաստային որոնում։

9 Համակարգի գործարկում և վերարտադրում

Ծրագիրը գտնվում է FakeNewsNet-master պանակի practical ենթապանակում։ start.command ֆայլը գործարկելուց հետո միջերեսը հասանելի է http://127.0.0.1:8000 հասցեով, API նկարագրությունը՝ /docs հասցեով։ Տեքստի վերլուծությունը կատարվում է /analyze մեթոդով։ Ապացույցներով ստուգումը կատարվում է /verify մեթոդով։ Առցանց MediaWiki որոնումը միացվում է համապատասխան ընտրանքով։

Ուսուցման վերարտադրման համար գործարկվում է python -m fakenews.train հրամանը։ Ապացույցների բազան կառուցվում է python -m fakenews.build_evidence, իսկ որոնումը գնահատվում է python -m fakenews.evaluate_evidence հրամանով։ NLI մոդելը և սկզբնական աղբյուրները տեղադրվում են python -m fakenews.setup_verifier հրամանով, իսկ նոր շղթան գնահատվում է python -m fakenews.evaluate_verifier --split test հրամանով։ Անհրաժեշտ փաթեթների տարբերակները ֆիքսված են requirements.txt ֆայլում։

Պահպանված են տվյալների մաքրման աուդիտը, train/valid/test մանիֆեստը, validation համեմատությունները, թեստային կանխատեսումները, սխալների ցանկը, շփոթության մատրիցները և աղբյուրների SHA-256 հեշերը։ Ծրագրային 50 ստուգումներն անցել են։ Բրաուզերում ստուգվել են աղբյուրով ուղղումը, փոփոխված պնդման դեպքում ձեռնպահ մնալը, արխիվային արդյունքը և փոքր էկրանի դասավորությունը։

10 Օգտագործված աղբյուրներ

[1] Wang W Y 2017 Liar Liar Pants on Fire A New Benchmark Dataset for Fake News Detection https://aclanthology.org/P17-2067/

[2] Alhindi T Petridis S Muresan S 2018 Where is Your Evidence Improving Fact Checking by Justification Modeling https://aclanthology.org/W18-5513/

[3] FakeNewsNet տվյալների և հավաքման կոդի պաշտոնական պահոց https://github.com/KaiDMML/FakeNewsNet

[4] LIAR-PLUS պաշտոնական պահոց https://github.com/Tariq60/LIAR-PLUS commit 992bfd97 555 631e48b6bddb1a87aa61c51ee1197

[5] scikit-learn TF-IDF փաստաթղթեր https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

[6] Google Fact Check Tools API որոնման փաստաթղթեր https://developers.google.com/fact-check/tools/api/reference/rest/v1alpha1/claims/search

[7] NASA Sun Facts https://science.nasa.gov/sun/facts/

[8] NASA Earth Facts https://science.nasa.gov/earth/facts/

[9] Cross Encoder NLI DeBERTa v3 small մոդելի փաստաթուղթ https://huggingface.co/cross-encoder/nli-deberta-v3-small

[10] MediaWiki Search API https://www.mediawiki.org/wiki/API:Search