Կեղծ լուրերի հայտնաբերման և ճշգրտման ավտոմատացված համակարգի մշակում

Գործնական մաս և փորձարարական արդյունքներ

Հետազոտական իրականացում անգլերեն տվյալներով

1 Իրականացված համակարգը

Իրականացվել է վերարտադրվող հետազոտական համակարգ՝ երկու տեքստային դասակարգիչով, աղբյուրների որոնմամբ, ապացույց–պնդում իմաստային համեմատությամբ և աղբյուրից վերցված ուղղման առաջարկով։ Ծրագիրն ունի հայերեն տեղային միջերես, իսկ մուտքային տեքստերը և ուսուցման տվյալներն անգլերեն են։ LIAR-ը օգտագործվում է անգլերեն պնդումների վեցաստիճան դասակարգման, FakeNewsNet-ը՝ անգլերեն վերնագրերի fake/real դասակարգման համար։ Այս խնդիրներն ունեն տարբեր դասեր և բարդություն, ուստի դրանց տոկոսները ուղղակի համեմատելի չեն։

2 Տվյալների նախնական մշակում

Կիրառվում են Unicode NFKC նորմալացում, HTML նշագրերի հեռացում, HTML entity-ների փոխակերպում, URL-ի ընդհանուր նշիչ, փոքրատառերի փոխակերպում և բացատների կարգավորում։ Թվերը և ժխտումը պահպանվում են։ Stopword-ների հեռացում և լեմատացում չեն կիրառվել։ Պիտակների հակասող օրինակները հեռացվում են, կրկնվող նորմալացված տեքստից պահպանվում է մեկ օրինակ։

Հավաքածու	Հում	Հակասող	Կրկնվող	Մնացած	Train / Valid / Test
liar	12 791	16	24	12 751	10 212 / 1277 / 1262
fakenewsnet	23 196	369	1239	21 588	15 111 / 3238 / 3239

LIAR-ում պահպանված են պաշտոնական բաժանումները՝ մաքրումից հետո։ FakeNewsNet-ի բաժանումը 70/15/15 է՝ seed=42, աղբյուրի և դասի համատեղ շերտավորմամբ։ Բաժանումների միջև նորմալացված ճշգրիտ տեքստային համընկնումների թիվը 0 է։ Տվյալների ամբողջության վրա նախնական հակասությունների մաքրումը փոխում է գնահատվող պոպուլյացիան։ Թեմատիկ կամ մոտ իմաստային կրկնությունները ամբողջությամբ չեն բացառվել։

3 Հատկանիշների դուրս բերում

Օգտագործվում է TF-IDF՝ մեկ և երկու բառից կազմված n-gram-ներով, min_df=2, max_df=0.98, առավելագույնը 60,000 հատկանիշ և sublinear_tf=True։ Բառապաշարը և IDF կշիռները հաշվարկվում են միայն ուսուցման հավաքածուից։ Գնահատման

տվյալները չեն մասնակցում հատկանիշների ուսուցմանը: URL-ները, աղբյուրի անունը և LIAR-ի պիտակից կախված խոսնակի հաշվիչները մոդելի մուտք չեն:

4 Սկզբնական մոդելների իրականացում

Համեմատվել են majority baseline, Complement Naive Bayes, Logistic Regression և Linear SVM մոդելները: Երկու վերջիններում կիրառվում է դասերի հավասարակշռված կշռում: Ընտրության միակ չափանիշը validation macro-F1-ն է: Ընտրված մոդելը պահպանվում է joblib ձևաչափով և օգտագործվում է FastAPI ծառայությունում:

liar validation արդյունքներ

Մոդել	Accuracy	Macro-F1
Logistic Regression	25.76%	25.96%
Linear SVM	24.67%	24.90%
Complement NB	25.14%	24.88%
majority	19.42%	5.42%

fakenewsnet validation արդյունքներ

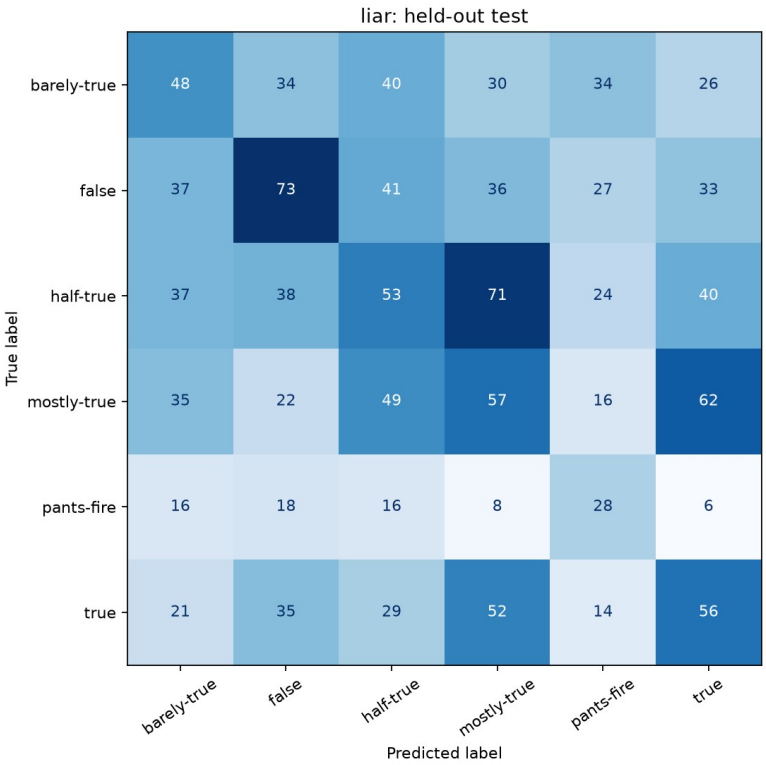
Մոդել	Accuracy	Macro-F1
Logistic Regression	82.00%	76.88%
Complement NB	82.95%	76.36%
Linear SVM	81.90%	76.21%
majority	75.94%	43.16%

5 Սկզբնական թեստային գնահատում

Հավաքածու	Accuracy	Macro precision	Macro recall	Macro-F1
liar	24.96%	24.72%	25.58%	24.90%
fakenewsnet	82.37%	75.91%	77.91%	76.79%

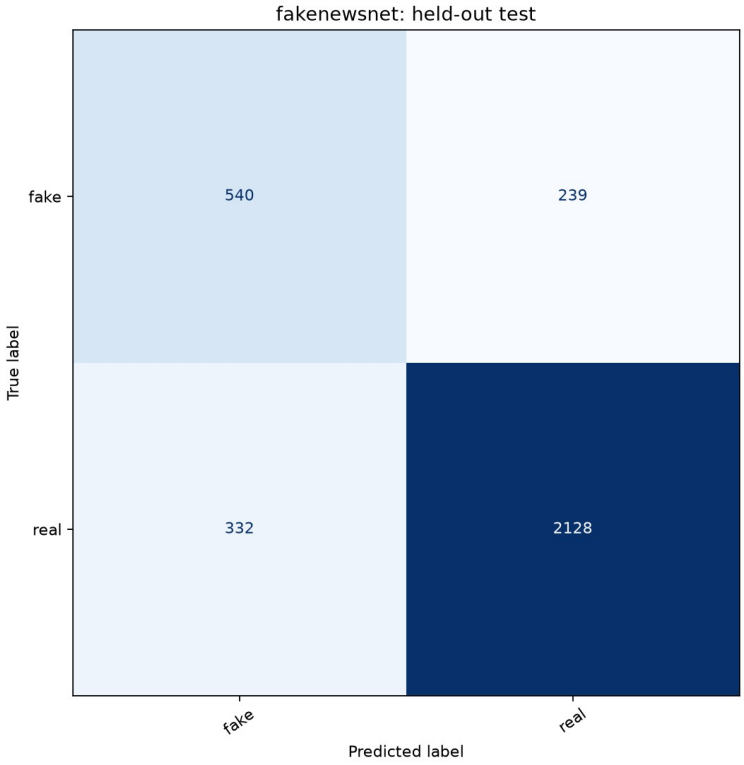
F1-ը precision-ի և recall-ի հարմոնիկ միջինն է: Macro-F1-ը դասերի F1-երի չկշռված միջինն է և ընտրվել է որպես հիմնական չափանիշ՝ դասերի անհավասարակշռությունը հաշվի առնելու համար:

liar: Macro-F1-ի 95% bootstrap միջակայքը՝ 22.40%–27.14% (500 վերանմուշառում, seed=42):



Նկար 1 LIAR թեստային շփոթության մատրից

fakenewsnet: Macro-F1-ի 95% bootstrap միջակայքը՝ 74.98%–78.48% (500 վերանմուշառում, seed=42):



Նկար 2 FakeNewsNet թեստային շփոթության մատրից

Աղբյուրների միջև տեղափոխում

Ուսուցման աղբյուր → թեստի աղբյուր	Accuracy	Macro-F1
gossipcop_to_politifact	57.82%	52.05%
politifact_to_gossipcop	47.25%	45.55%

Այս փորձը ցույց է տալիս աղբյուրի փոփոխության նկատմամբ զգայունություն: Այն օգտագործում է ընտրված մոդելի նույն կառուցվածքը՝ վերաուսուցված միայն սկզբնական train-ի համապատասխան աղբյուրով: Թիրախային test-ը չի օգտագործվում ուսուցման համար: Փոքր PolitiFact ենթաբաժինը սահմանափակում է եզրահանգումների կայունությունը:

6 Ճշգրտում և ապացույցներ

LIAR-ի սկզբնական ֆայլերում փաստաստուգողների հիմնավորումները բացակայում են: Այդ բացը լրացվել է LIAR-PLUS հետազոտական հավելումով: Այն չի փոխարինում սկզբնական տվյալները և չի մասնակցում դասակարգիչների գնահատմանը: 10,242 հում գրառումից ինդեքսավորվել է 10,090-ը: Բացառվել են մաքրված train-ին չհամապատասխանող 30 գրառում, պնդման կամ պիտակի անհամապատասխանությամբ 6 գրառում և անբավարար հիմնավորմամբ 116 գրառում:

Որոնումը համատեղում է բառային TF-IDF կոսինուսային նմանությունը՝ 0.65 կշռով, և նիշային TF-IDF նմանությունը՝ 0.35 կշռով: Ինդեքսավորվում են պնդումները: Յուրաքանչյուր արդյունքին կցված են սկզբնական խոսնակը, համատեքստը, պատմական գնահատականը և փաստաստուգողի հիմնավորման հատվածը: Աղբյուրների հղումները տանում են ամրագրված Git commit-ի տվյալների համապատասխան տողին, ոչ ենթադրված կամ հորինված հոդվածի հասցեին:

Ճշգրիտ համընկնումը վերադարձնում է արխիվային գնահատականն ու հիմնավորումը: Սա պատմական տվյալ է, ոչ այսօրվա ճշմարտության վերահաստատում: Վերաշարադրված կամ փոփոխված պնդման համար ցուցադրվում են առավելագույնը հինգ հարակից նյութեր՝ առանց դրանց գնահատականը նոր պնդմանը վերագրելու: Արխիվային որոնումը ինքնուրույն նոր ուղղված լուր չի գեներացնում. նոր պնդումների ուղղման առանձին մեխանիզմը նկարագրված է ստորև: NASA-ի չորս աղբյուրով օրինակները պահպանվել են որպես նախապես կազմված ուղղման ցուցադրություն:

Որոնման առանձին գնահատում

Փորձարկվել են նախապես կազմված 20 ձեռքով վերաշարադրված հարցումներ՝ հայտնի արխիվային թիրախներով: Հարցումները ինդեքսի ճշգրիտ կրկնություններ չեն: Ճիշտ նյութը առաջին տեղում գտնվել է 16 դեպքում՝ Recall@1 = 80%, առաջին հինգում՝ 20 դեպքում՝ Recall@5 = 100%: MRR@5 = 0.8917: Փորձը փոքր զարգացման հավաքածու է և չի հանդիսանում անկախ իրական աշխարհի փաստաստուգման benchmark: Կշիռները արդյունքներից հետո չեն կարգավորվել:

LIAR test-ի բոլոր 1,262 պնդումները ստուգվել են ինդեքսի ճշգրիտ համընկնման նկատմամբ. համընկնումների թիվը 0 է: Թվերի փոփոխմամբ և ժխտման ավելացմամբ կազմված 60 դեպքերում ավտոմատ ուղղում չի տրվել: Test-ից պատահական ընտրված 50 պնդումների համար նույնպես ուղղում չի ստեղծվել: Այս ստուգումները հաստատում են ձեռնպահ մնալու կանոնը, ոչ փաստային ճշմարտության հայտնաբերման որակը:

Google Fact Check միակցիչը վերադարձնում է հրապարակումների հղումներ և գնահատականներ՝ համապատասխանությունը ստուգելու համար: Այն փորձարկվել է մոդելավորված պատասխաններով, դատարկ կամ սխալ կառուցվածքով տվյալներով և ցանցային խափանումներով: Իրական API բանալիով փորձարկումը բաց է մնում:

Աղբյուրներ՝ https://github.com/Tariq60/LIAR-PLUS և https://aclanthology.org/W18-5513/ : LIAR-PLUS-ը օգտագործվում է հետազոտական նպատակով:

Նոր պնդումների ապացույցներով ստուգում

Իրականացվել է առանձին /verify շղթա՝ մուտքային տեքստի բաժանում պնդումների, աղբյուրների ստացում, համապատասխան հատվածների ընտրություն, բնական լեզվի եզրահանգման NLI մոդելի գնահատում և աղբյուրի նախադասությունից կազմված ուղղում: Մեկ հարցումը ընդունում է մինչև հինգ կարճ պնդում: Բարդ համակցված պնդումների դեպքում պահանջվում է դրանք բաժանել, որպեսզի մեկ մասի ապացույցը չվերագրվի ամբողջ տեքստին:

Սկզբնական աղբյուրների կորպուսը ներառում է NASA-ի տասը փաստագրական էջի պահպանված պատճենները։ Օգտատերը կարող է նշել լրացուցիչ NASA կամ անգլերեն Wikipedia հոդվածի HTTPS հասցե։ Առցանց ռեժիմում MediaWiki որոնումը ստանում է նոր հոդվածների ներածական հատվածները՝ առանց API բանալու։ Պահպանվում են աղբյուրի հասցեն, վերնագիրը, ստացման ժամանակը և տեքստի SHA-256 հեշը։ Wikipedia-ի դեպքում վերադարձվում է կոնկրետ վերանայման հասցեն։

Ապացույցների ընտրությունը սկսվում է պնդման հիմնական առարկայի համընկնումից։ Այնուհետև բառային TF-IDF-ով ընտրվում է առավելագույնը 16 հատված՝ առնվազն 0.14 կոսինուսային նմանությամբ։ Այս շեմերը լեզվական ու թեմատիկ նախնական զտիչներ են, ոչ պնդման ճշմարտության ապացույց։

Իմաստային համեմատությունն իրականացնում է cross-encoder/nli-deberta-v3-small մոդելը։ Այն իր հեղինակների կողմից նախապես ուսուցանվել է SNLI և MultiNLI տվյալներով։ Այս աշխատանքում այդ մոդելը չի վերաուսուցվել LIAR-ի կամ FakeNewsNet-ի վրա։ Մեր տվյալներով իրական ուսուցված մոդելները մնում են նախորդ բաժինների տեքստային դասակարգիչները։ NLI-ի համար օգտագործվում է ամրագրված fa2804872c3b4bd748f38c0185cc85775361e735 վերանայումը։

NLI-ն գնահատում է երեք հարաբերություն՝ հաստատում, հակասություն և չեզոքություն։ Վճռորոշ գնահատականի շեմը 0.92 է։ Սա ճշմարտության 92% հավանականություն չէ. մոդելի ելքերը չեն կալիբրացվել իրական լուրերի հավանականությունների նկատմամբ։ Բարձր հաստատում և բարձր հակասություն միաժամանակ ունենալու դեպքում համակարգը վերադարձնում է հակասող ապացույցների վիճակ։

Հակասության դեպքում առաջարկվող ուղղումը ընտրված աղբյուրի բառացի նախադասությունն է՝ աղբյուրի վերնագրով և հղումով։ Այսպիսով համակարգը կարող է նոր մուտքային պնդման համար ինքնաշխատ կազմել աղբյուրի վրա հիմնված փոխարինող տեքստ՝ առանց ազատ գեներացմամբ նոր փաստ հորինելու։ Բազմապնդում տեքստի ամբողջական ուղղումը տրվում է միայն այն դեպքում, երբ բոլոր մասերի համար կա վճռորոշ գնահատական։ Անորոշ մասի դեպքում ամբողջական վերաշարադրում չի ներկայացվում։

Նոր շղթայի զարգացման և թեստային գնահատում

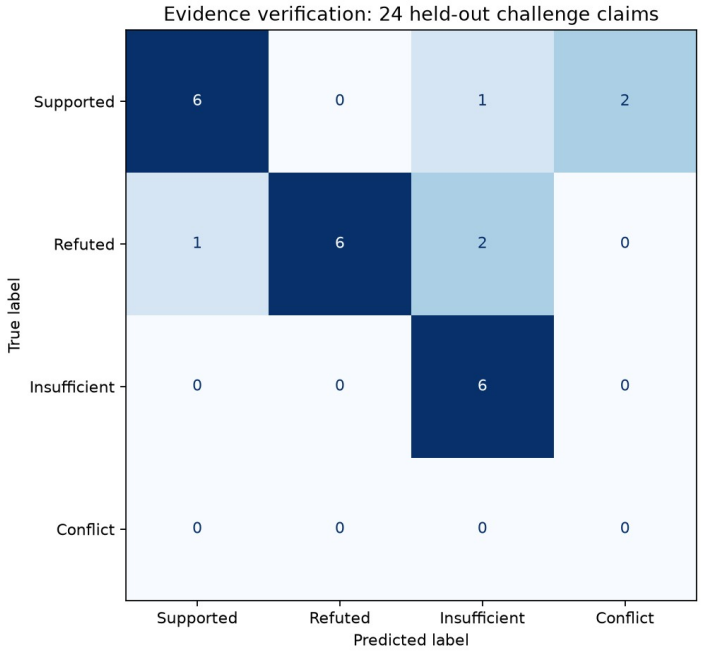
Նախապես կազմվել են 12 զարգացման և 24 թեստային օրինակներ՝ հաստատվող, հերքվող և բավարար ապացույց չունեցող դասերով։ Զարգացման օրինակները վերաբերում են Արեգակին, Երկրին, Լուսնին և Մարսին, իսկ թեստային փաստային օրինակները՝ այլ մոլորակների։ Որոշումներն ու շեմերը ֆիքսվել են զարգացման փուլից հետո։ Թեստի արդյունքները չեն օգտագործվել հաջորդ կարգաբերման համար։

Զարգացման ընթացքում համեմատվել է նաև MiniLM տարբերակը։ Թեմային չառնչվող հատվածների սխալ հակասությունները հանգեցրել են առարկայի նախնական զտիչի ավելացմանը։ Ընտրվել է DeBERTa տարբերակը, որի զարգացման 12 օրինակներից 11-ի ելքը ճիշտ է եղել։

Չափանիշ	Թեստային արդյունք
Օրինակների թիվ	24
Ճիշտ ընդհանուր ելքեր	18 / 24
Accuracy	75.00%
Macro-F1՝ ելքային չորս վիճակներով	58.75%
Առաջարկված ուղղումներ	6
Ճիշտ հերքումներ առաջարկված ուղղումների մեջ	6 / 6
Աղբյուրի բառացի հատվածին համապատասխանություն	6 / 6

Macro-F1-ի հաշվարկում ներառված է նաև կանխատեսված «հակասող ապացույցներ» վիճակը, որի համար այս փոքր հավաքածուում առանձին gold օրինակներ չկան։ Հետևաբար այս չափանիշը չի համեմատվում անմիջապես LIAR-ի կամ FakeNewsNet-ի դասակարգման F1-ի հետ։

Եղել են հինգ ձեռնպահ մնալու կամ հակասության դեպքեր՝ այն օրինակների համար, որտեղ gold գնահատականը վճռորոշ էր, և մեկ սխալ հաստատում՝ Mercury has a moon պնդման համար։ Այդ սխալը պահպանվել է հաշվետվությունում։ Ուղղումների 6/6 արդյունքը վերաբերում է ընդամենը վեց դեպքի և չի նշանակում համընդհանուր 100% ճշգրտություն։ Բառացի համապատասխանությունը հաստատում է աղբյուրի պահպանումը, ոչ ինքնաբերաբար ուղղման իմաստային բավարարությունը։



Նկար 3 Ապացույցներով ստուգում թեստային շփոթության մատրից

Թեստը փոքր, ձեռքով կազմված գիտական և անորոշ պնդումների հավաքածու է, ոչ անկախ լայնածավալ նորությունների benchmark: NLI մոդելը կարող է սխալվել, իսկ աղբյուրները կարող են լինել հնացած կամ անբավարար: Ընդհանուր համակարգի կիրառելիությունը սահմանափակվում է հասանելի և համապատասխան աղբյուրներով:

Իրական առցանց փորձարկում

Իրական MediaWiki հարցումներով փորձարկվել են France's capital city is Berlin և France's capital city is Paris պնդումները: Առաջինի համար համակարգը վերադարձրել է Փարիզը նշող աղբյուրային ուղղում և հոդվածի վերանայման հղումը, երկրորդի համար՝ հաստատող գնահատական: Երկու դեպքում էլ աղբյուրների որոնումն ավարտվել է առանց provider սխալների: Պատասխանների ամբողջ կառուցվածքն ու ժամանակները պահպանված են reports/live_verification.json ֆայլում:

Google Fact Check-ը պահպանված է որպես լրացուցիչ ընտրովի միակցիչ: Դրա իրական բանալիով փորձարկում չի կատարվել: Հիմնական առցանց շղթան աշխատում է առանց այդ միակցիչի՝ արդեն փորձարկված MediaWiki հասանելիությամբ:

7 Ծրագրային ստուգումներ

Անցել են 53 ավտոմատ ստուգումները: Դրանք ընդգրկում են նախնական մաքրումը, կրկնությունների արտահոսքը, accuracy-ի վերահաշվարկը, արխիվի train-only սահմանափակումը, ծառայության մուտքային վավերացումը, չաջակցվող գրային համակարգերը, արտաքին ծառայությունների խափանումներն ու սխալ JSON պատասխանները: Նոր ստուգումները ներառում են թեմային չառնչվող ապացույցների մերժումը, հակասող աղբյուրների դեպքում ձեռնպահ մնալը,

աղբյուրի բառացի պահպանումը և իրական NLI մոդելով նոր ձևակերպման ուղղումը։

Աղբյուրի հասցեների համար թույլատրված են միայն NASA-ի և անգլերեն Wikipedia-ի HTTPS հոդվածները։ Տեղային կամ այլ տիրույթներ, օգտանուն կամ գաղտնաբառ պարունակող URL-ներ և ոչ ստանդարտ պորտեր չեն ընդունվում։ Բրաուզերում ստուգվել են երկու վերլուծական ուղիները, սխալ մուտքերն ու փոքր էկրանի դասավորությունը։ Թեստերի և բրաուզերի արդյունքները պահպանված են reports/tests.log և reports/browser_checks.json ֆայլերում։

8 Ճշտության բարելավման ընդլայնված փորձարկումներ

Հաջորդ փուլում յուրաքանչյուր հավաքածուի համար համեմատվել է 30 տարբերակ՝ ներառյալ նախկին մոդելները, իմաստային ներկայացումներով դասակարգիչները, բառային ու նիշային և իմաստային հատկանիշների համադրությունները, լրացուցիչ ուսուցված լեզվային մոդելը և երեք կշռված համադրությունները։ Բոլոր ընտրությունները կատարվել են validation macro-F1 չափանիշով։ Սկզբնական train, validation և test բաժանումները պահպանվել են։

Օգտագործվել է sentence-transformers/all-MiniLM-L6-v2 մոդելը՝ 1110a243fdf4706b3f48f1d95db1a4f5529b4d41 ամրագրված տարբերակով։ Սառեցված մոդելի ելքերը attention mask-ով միջինացվել և L2 նորմավորվել են։ Առանձին փորձով լեզվային մոդելի բոլոր կշիռները լրացուցիչ ուսուցվել են հենց LIAR-ի և FakeNewsNet-ի ուսուցման տեքստերով։ Սա տարբերվում է NLI փաստաստուգիչից, որը այստեղ լրացուցիչ չի ուսուցվել։

Լրացուցիչ ուսուցումն օգտագործել է AdamW, 0.00002 ուսուցման արագություն, 0.01 weight decay, 32 օրինակով խմբեր, առավելագույնը 128 token և seed=42։ Դասերի կշիռները հաշվարկվել են միայն train-ից՝ հակադարձ հաճախականության քառակուսի արմատով։ Նախատեսված հինգ epoch-ից յուրաքանչյուր մոդելի համար կատարվել է չորսը. երկու հաջորդական validation չբարելավումից հետո ուսուցումը դադարեցվել է։ Երկուսի լավագույն checkpoint-ը երկրորդ epoch-ից է։

Երկու հավաքածուների համար էլ ընտրվել է լեզվային մոդելի և լավագույն ոչ նեյրոնային թեկնածուի հավանականությունների 50/50 համադրությունը։ LIAR-ի վավերացման macro-F1-ը 27.77% է, FakeNewsNet-ինը՝ 80.44%։ Հաջորդ աղյուսակը ներկայացնում է արդեն ընտրված մոդելների թեստային արդյունքները։

Հավաքածու	Նախկին accuracy	Նոր accuracy	Նախկին macro-F1	Նոր macro-F1
LIAR	24.96%	26.31%	24.90%	26.38%
FakeNewsNet	82.37%	85.71%	76.79%	79.56%

FakeNewsNet-ի accuracy-ի աճը 3.33 տոկոսային կետ է։ Նույն թեստային օրինակներով զույգ bootstrap-ի 1000 վերանմուշառմամբ աճի 95% միջակայքը 2.28–4.35 տոկոսային կետ է։ Macro-F1-ի աճի միջակայքը 1.35–4.14 տոկոսային կետ է։ LIAR-ի accuracy-ի աճը

1.35 տոկոսային կետ է՝ −0.08–2.77 միջակայքով, որը ներառում է զրոն։ Դրա macro-F1-ի աճի միջակայքը 0.03–2.92 տոկոսային կետ է՝ ստորին սահմանը զրոյին մոտ։ Հետևաբար LIAR-ի բարելավման վերաբերյալ եզրակացությունը պետք է զգուշավոր լինի։

Աճը բոլոր չափանիշների համաժամանակյա բարելավում չէ։ FakeNewsNet-ի «fake» դասի precision-ը 61.93%-ից դարձել է 73.10%, բայց recall-ը 69.32%-ից նվազել է 64.18%։ Իրական լուրերի վրա կեղծ ահազանգերը նվազել են, իսկ բաց թողնված կեղծ լուրերի բաժինը մեծացել է։ Ընտրված տարբերակը լավագույնն է փորձարկվածների մեջ validation macro-F1-ով, ոչ բոլոր հնարավոր նպատակների համար։

Թեստային բաժանումը նախկին փուլերում արդեն գնահատված էր։ Այն այս փուլում չի մասնակցել մոդելի ընտրությանը, սակայն նոր կույր անկախ թեստ չի համարվում։ Նախապես ուսուցված մոդելի սկզբնական կորպուսի հնարավոր համընկնումը հետազոտական տվյալների հետ բացառված չէ։ Ավելի ուժեղ ընդհանրացման պնդման համար անհրաժեշտ է նոր աղբյուրներից կամ ավելի ուշ ժամանակահատվածից անկախ գնահատում։

Փաստաստուգման համար առանձին համեմատվել է ապացույցների դասավորման, քանակի և որոշման շեմի 48 եզակի համակցություն։ Ընտրությունը կատարվել է միայն նախկին 12 development պնդումներով։ Ընտրված փորձնական տարբերակը հին 24 պնդումների թեստում ստացել է 19 ճիշտ ելք՝ 79.17%, նախկին 18-ի՝ 75%-ի փոխարեն։ Միայն մեկ օրինակով աճը և փոքր զարգացման հավաքածուն բավարար չեն այդ տարբերակը հիմնական դարձնելու համար։ Գործող NLI շղթան պահպանում է սկզբնական տարբերակը և 75% փաստագրված արդյունքը։

Բարելավված դասակարգիչները միացված են ծառայությանը models/active_models.json գրանցամատյանով։ Սկզբնական մոդելներն ու բոլոր հին չափումները պահպանված են։ Նոր ընտրությունները, ուսուցման պատմությունը, թեստային կանխատեսումները, սխալները և վստահության միջակայքերը գտնվում են reports/optimization պանակում։

9 Եզրակացություններ

Իրականացվել են թեմայի գործնական հիմնական փուլերը՝ տվյալների նախնական մշակում, հատկանիշների դուրս բերում, մոդելների ուսուցում, գնահատում, աղբյուրների որոնում և աղբյուրով հիմնավորված ուղղման առաջարկ։ Դասակարգումը, արխիվային փաստաստուգումը և նոր պնդումների NLI ստուգումը ներկայացված են որպես տարբեր գործողություններ՝ իրենց չափումներով։

Բարելավված FakeNewsNet դասակարգչի արդյունքը 85.71% accuracy և 79.56% macro-F1 է։ LIAR-ի վեց դասով արդյունքը 26.31% accuracy և 26.38% macro-F1 է։ Այս տարբերությունը ցույց է տալիս, որ տեքստային օրինաչափությունների ճանաչումը նույնը չէ, ինչ փաստացի ճշմարտության որոշումը։ Աղբյուրների միջև տեղափոխման դեպքում որակի նվազումը ևս սահմանափակում է ընդհանրացումը։

Նոր պնդումների ստուգման շղթան 24 օրինակով թեստում տվել է 75% ճիշտ ելք։ Այն կարողացել է աղբյուրային ուղղում առաջարկել վեց հերքվող պնդման համար, ինչպես նաև իրական առցանց որոնմամբ մշակել աղբյուրների սկզբնական կորպուսից դուրս օրինակ։ Համակարգը կատարում է ինքնաշխատ, աղբյուրին կապված ուղղման առաջարկ, իսկ անհամապատասխան կամ հակասող ապացույցների դեպքում ձեռնպահ է մնում։

Ստացված իրականացումը հետազոտական համակարգ է՝ սահմանված մուտքերով և գնահատված սահմանափակումներով։ Այն չի երաշխավորում ցանկացած նորության անսխալ ստուգում։ Հայերենը կիրառված է միջերեսում և հաշվետվությունում, իսկ դասակարգումն ու NLI-ն նախատեսված են անգլերենի համար։ Հետագա զարգացումը կարող է ներառել ավելի մեծ անկախ benchmark, հայերեն պիտակավորված տվյալներ, ժամանակային վավերացում և ավելի ճշգրիտ իմաստային որոնում։

10 Համակարգի գործարկում և վերարտադրում

Ծրագիրը գտնվում է FakeNewsNet-master պանակի practical ենթապանակում։ start.command ֆայլը գործարկելուց հետո միջերեսը հասանելի է http://127.0.0.1:8000 հասցեով, API նկարագրությունը՝ /docs հասցեով։ Տեքստի վերլուծությունը կատարվում է /analyze մեթոդով։ Ապացույցներով ստուգումը կատարվում է /verify մեթոդով։ Առցանց MediaWiki որոնումը միացվում է համապատասխան ընտրանքով։

Ուսուցման վերարտադրման համար գործարկվում է python -m fakenews.train հրամանը։ Ապացույցների բազան կառուցվում է python -m fakenews.build_evidence, իսկ որոնումը գնահատվում է python -m fakenews.evaluate_evidence հրամանով։ NLI մոդելը և սկզբնական աղբյուրները տեղադրվում են python -m fakenews.setup_verifier հրամանով, իսկ նոր շղթան գնահատվում է python -m fakenews.evaluate_verifier --split test հրամանով։ Անհրաժեշտ փաթեթների տարբերակները ֆիքսված են requirements.txt ֆայլում։

Պահպանված են տվյալների մաքրման աուդիտը, train/valid/test մանիֆեստը, validation համեմատությունները, թեստային կանխատեսումները, սխալների ցանկը, շփոթության մատրիցները և աղբյուրների SHA-256 հեշերը։ Ծրագրային 53 ստուգումներն անցել են։ Բրաուզերում ստուգվել են աղբյուրով ուղղումը, փոփոխված պնդման դեպքում ձեռնպահ մնալը, արխիվային արդյունքը և փոքր էկրանի դասավորությունը։

Բարելավման վերարտադրման շղթան՝ python -m fakenews.setup_encoder, python -m fakenews.improve, python -m fakenews.optimize, python -m fakenews.evaluate_optimized և python -m fakenews.activate_optimized։ Սկզբնական դասակարգիչները և նոր ընտրված տարբերակները պահպանված են առանձին։ Ծառայության վերագործարկումից հետո բեռնվում է ակտիվ գրանցամատյանը։

11 Օգտագործված աղբյուրներ

[1] Wang W Y 2017 Liar Liar Pants on Fire A New Benchmark Dataset for Fake News Detection https://aclanthology.org/P17-2067/

[2] Alhindi T Petridis S Muresan S 2018 Where is Your Evidence Improving Fact Checking by Justification Modeling https://aclanthology.org/W18-5513/

[3] FakeNewsNet տվյալների և հավաքման կոդի պաշտոնական պահոց https://github.com/KaiDMML/FakeNewsNet

[4] LIAR-PLUS պաշտոնական պահոց https://github.com/Tariq60/LIAR-PLUS commit 992bfd97 555 631e48b6bddb1a87aa61c51ee1197

[5] scikit-learn TF-IDF փաստաթղթեր https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

[6] Google Fact Check Tools API որոնման փաստաթղթեր https://developers.google.com/fact-check/tools/api/reference/rest/v1alpha1/claims/search

[7] NASA Sun Facts https://science.nasa.gov/sun/facts/

[8] NASA Earth Facts https://science.nasa.gov/earth/facts/

[9] Cross Encoder NLI DeBERTa v3 small մոդելի փաստաթուղթ https://huggingface.co/cross-encoder/nli-deberta-v3-small

[10] MediaWiki Search API https://www.mediawiki.org/wiki/API:Search

[11] Sentence Transformers all MiniLM L6 v2 մոդելի նկարագրություն https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2