Կեղծ լուրերի հայտնաբերման և ճշգրտման ավտոմատացված համակարգի մշակում

Գործնական մաս և փորձարարական արդյունքներ

Հետազոտական իրականացում անգլերեն տվյալներով

1 Իրականացված համակարգը

Իրականացվել է վերարտադրվող հետազոտական համակարգ՝ երկու անկախ դասակարգիչով, աղբյուրների որոնմամբ և հայերեն տեղային միջերեսով: LIAR-ը օգտագործվում է անգլերեն պնդումների վեցաստիճան դասակարգման, FakeNewsNet-ը՝ անգլերեն վերնագրերի fake/real դասակարգման համար: Այս խնդիրներն ունեն տարբեր դասեր և բարդություն, ուստի դրանց տոկոսները ուղղակի համեմատելի չեն:

2 Տվյալների նախնական մշակում

Կիրառվում են Unicode NFKC նորմալացում, HTML նշագրերի հեռացում, HTML entity-ների փոխակերպում, URL-ի ընդհանուր նշիչ, փոքրատառերի փոխակերպում և բացատների կարգավորում: Թվերը և ժխտումը պահպանվում են: Stopword-ների հեռացում և լեմատացում չեն կիրառվել: Պիտակների հակասող օրինակները հեռացվում են, կրկնվող նորմալացված տեքստից պահպանվում է մեկ օրինակ:

Հավաքածու	Հում	Հակասող	Կրկնվող	Մնացած	Train / Valid / Test
liar	12 791	16	24	12 751	10 212 / 1277 / 1262
fakenewsnet	23 196	369	1239	21 588	15 111 / 3238 / 3239

LIAR-ում պահպանված են պաշտոնական բաժանումները՝ մաքրումից հետո: FakeNewsNet-ի բաժանումը 70/15/15 է՝ seed=42, աղբյուրի և դասի համատեղ շերտավորմամբ: Բաժանումների միջև նորմալացված ճշգրիտ տեքստային համընկնումների թիվը 0 է: Տվյալների ամբողջության վրա նախնական հակասությունների մաքրումը փոխում է գնահատվող պոպուլյացիան: Թեմատիկ կամ մոտ իմաստային կրկնությունները ամբողջությամբ չեն բացառվել:

3 Հատկանիշների դուրս բերում

Օգտագործվում է TF-IDF՝ մեկ և երկու բառից կազմված n-gram-ներով, min_df=2, max_df=0.98, առավելագույնը 60,000 հատկանիշ և sublinear_tf=True: Բառապաշարը և IDF կշիռները հաշվարկվում են միայն ուսուցման հավաքածուից: Գնահատման տվյալները չեն մասնակցում հատկանիշների ուսուցմանը: URL-ները, աղբյուրի անունը և LIAR-ի պիտակից կախված խոսնակի հաշվիչները մոդելի մուտք չեն:

4 Մոդելների իրականացում

Համեմատվել են majority baseline, Complement Naive Bayes, Logistic Regression և Linear SVM մոդելները: Երկու վերջիններում կիրառվում է դասերի հավասարակշռված կշռում: Ընտրության միակ չափանիշը validation macro-F1-ն է: Ընտրված մոդելը պահպանվում է joblib ձևաչափով և օգտագործվում է FastAPI ծառայությունում:

liar validation արդյունքներ

Մոդել	Accuracy	Macro-F1
Logistic Regression	25.76%	25.96%
Linear SVM	24.67%	24.90%
Complement NB	25.14%	24.88%
majority	19.42%	5.42%

fakenewsnet validation արդյունքներ

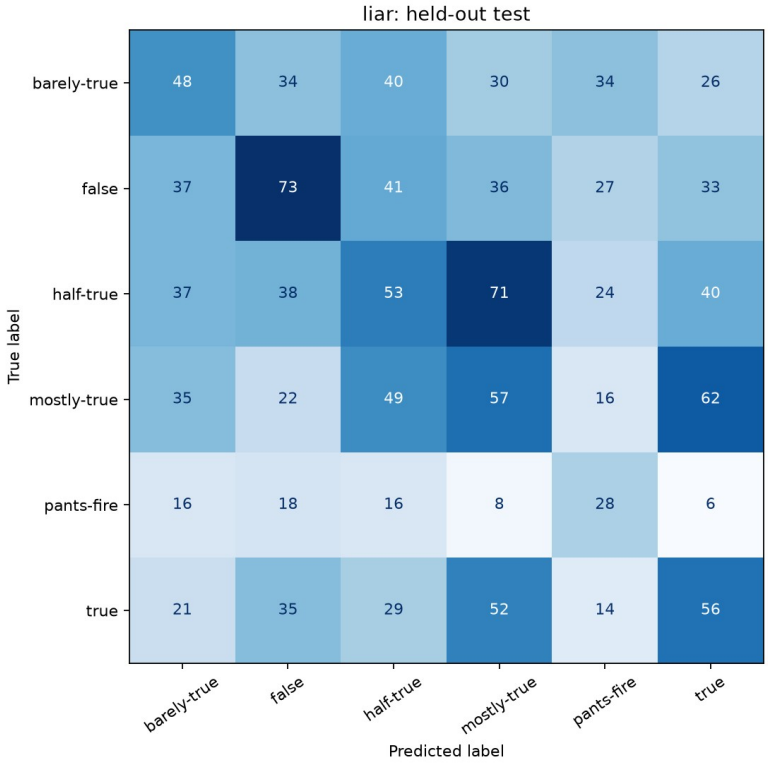
Մոդել	Accuracy	Macro-F1
Logistic Regression	82.00%	76.88%
Complement NB	82.95%	76.36%
Linear SVM	81.90%	76.21%
majority	75.94%	43.16%

5 Անկախ թեստային գնահատում

Հավաքածու	Accuracy	Macro precision	Macro recall	Macro-F1
liar	24.96%	24.72%	25.58%	24.90%
fakenewsnet	82.37%	75.91%	77.91%	76.79%

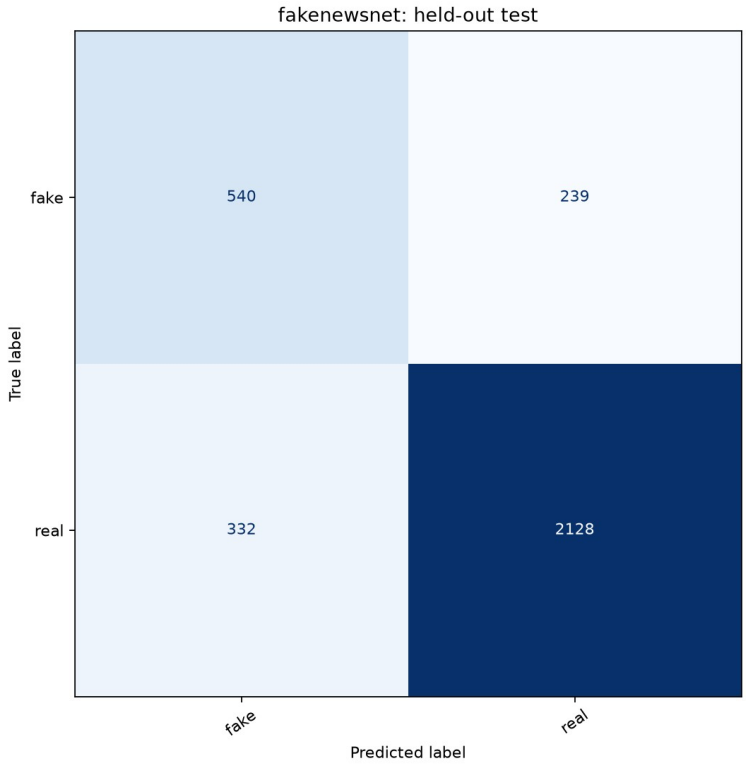
F1-ը precision-ի և recall-ի հարմոնիկ միջինն է: Macro-F1-ը դասերի F1-երի չկշռված միջինն է և ընտրվել է որպես հիմնական չափանիշ՝ դասերի անհավասարակշռությունը հաշվի առնելու համար:

liar: Macro-F1-ի 95% bootstrap միջակայքը՝ 22.40%–27.14% (500 վերանմուշառում, seed=42):



Նկար 1 LIAR թեստային շփոթության մատրից

fakenewsnet: Macro-F1-ի 95% bootstrap միջակայքը՝ 74.98%–78.48% (500 վերանմուշառում, seed=42):



Նկար 2 FakeNewsNet թեստային շփոթության մատրից

Աղբյուրների միջև տեղափոխում

Ուսուցման աղբյուր → թեստի աղբյուր	Accuracy	Macro-F1
gossipcop_to_politifact	57.82%	52.05%
politifact_to_gossipcop	47.25%	45.55%

Այս փորձը ցույց է տալիս աղբյուրի փոփոխության նկատմամբ զգայունություն։ Այն օգտագործում է ընտրված մոդելի նույն կառուցվածքը՝ վերաուսուցված միայն սկզբնական train-ի համապատասխան աղբյուրով։ Թիրախային test-ը չի օգտագործվում ուսուցման համար։ Փոքր PolitiFact ենթաբաժինը սահմանափակում է եզրահանգումների կայունությունը։

6 Ճշգրտում և ապացույցներ

LIAR-ի սկզբնական ֆայլերում փաստաստուգողների հիմնավորումները բացակայում են։ Այդ բացը լրացվել է LIAR-PLUS հետազոտական հավելումով։ Այն չի փոխարինում սկզբնական տվյալները և չի մասնակցում դասակարգիչների գնահատմանը։ 10,242 հում գրառումից ինդեքսավորվել է 10,090-ը։ Բացառվել են մաքրված train-ին չհամապատասխանող 30 գրառում, պնդման կամ պիտակի անհամապատասխանությամբ 6 գրառում և անբավարար հիմնավորմամբ 116 գրառում։

Որոնումը համատեղում է բառային TF-IDF կոսինուսային նմանությունը՝ 0.65 կշռով, և նիշային TF-IDF նմանությունը՝ 0.35 կշռով։ Ինդեքսավորվում են պնդումները։ Յուրաքանչյուր արդյունքին կցված են սկզբնական խոսնակը, համատեքստը, պատմական գնահատականը և փաստաստուգողի հիմնավորման հատվածը։ Աղբյուրների հղումները տանում են ամրագրված Git commit-ի տվյալների համապատասխան տողին, ոչ ենթադրված կամ հորինված հոդվածի հասցեին։

Ճշգրիտ համընկնումը վերադարձնում է արխիվային գնահատականն ու հիմնավորումը։ Սա պատմական տվյալ է, ոչ այսօրվա ճշմարտության վերահաստատում։ Վերաշարադրված կամ փոփոխված պնդման համար ցուցադրվում են առավելագույնը հինգ հարակից նյութեր՝ առանց դրանց գնահատականը նոր պնդմանը վերագրելու։ Նոր ուղղված լուրի գեներացում չի կատարվում։ NASA-ի չորս աղբյուրով օրինակները պահպանվել են որպես նախապես կազմված ուղղման ցուցադրություն։

Որոնման առանձին գնահատում

Փորձարկվել են նախապես կազմված 20 ձեռքով վերաշարադրված հարցումներ՝ հայտնի արխիվային թիրախներով։ Հարցումները ինդեքսի ճշգրիտ կրկնություններ չեն։ Ճիշտ նյութը առաջին տեղում գտնվել է 16 դեպքում՝ Recall@1 = 80%, առաջին հինգում՝ 20 դեպքում՝ Recall@5 = 100%։ MRR@5 = 0.8917։ Փորձը փոքր զարգացման հավաքածու է և չի հանդիսանում անկախ իրական աշխարհի փաստաստուգման benchmark։ Կշիռները արդյունքներից հետո չեն կարգավորվել։

LIAR test-ի բոլոր 1,262 պնդումները ստուգվել են ինդեքսի ճշգրիտ համընկնման նկատմամբ. համընկնումների թիվը 0 է: Թվերի փոփոխմամբ և ժխտման ավելացմամբ կազմված 60 դեպքերում ավտոմատ ուղղում չի տրվել: Test-ից պատահական ընտրված 50 պնդումների համար նույնպես ուղղում չի ստեղծվել: Այս ստուգումները հաստատում են ձեռնպահ մնալու կանոնը, ոչ փաստային ճշմարտության հայտնաբերման որակը:

Google Fact Check միակցիչը վերադարձնում է հրապարակումների հղումներ և գնահատականներ՝ համապատասխանությունը ստուգելու համար: Այն փորձարկվել է մոդելավորված պատասխաններով, դատարկ կամ սխալ կառուցվածքով տվյալներով և ցանցային խափանումներով: Իրական API բանալիով փորձարկումը բաց է մնում:

Աղբյուրներ՝ https://github.com/Tariq60/LIAR-PLUS և https://aclanthology.org/W18-5513/ : LIAR-PLUS-ը օգտագործվում է հետազոտական նպատակով:

7 Ծրագրային ստուգումներ

Ավտոմատ ստուգումները ներառում են պիտակների հակասություններ, կրկնությունների արտահոսք, հաշվետվության accuracy-ի վերահաշվարկ, իրական ուսուցված մոդելներով API կանչեր, չափազանց երկար կամ դատարկ մուտք, չաջակցվող գրային համակարգերով տեքստ, անհայտ բառապաշար, ժխտումով կամ թվով փոփոխված պնդման սխալ ճշգրտման կանխում, API բանալու բացակայություն և արտաքին ծառայության խափանում: Արդյունքը պահպանված է reports/tests.log-ում:

8 Եզրակացություններ

FakeNewsNet-ի վերնագրերում տեքստային օրինաչափությունները թույլ են տալիս ստանալ 82.37% accuracy և 76.79% macro-F1, սակայն աղբյուրների միջև որակի անկումը թույլ չի տալիս արդյունքը ընդհանրացնել բոլոր նորություններին: LIAR-ի վեց դասով արդյունքը՝ 24.96% accuracy և 24.90% macro-F1, մատնանշում է կարճ պնդումների տեքստով ճշմարտացիության որոշման սահմանափակ հնարավորությունը: Այդ մոդելը կարող է լինել հետազոտական ելակետ, ոչ վստահելի փաստաստուգիչ:

Հաջորդ զարգացման ուղղություններն են անկախ փաստաստուգման կորպուսը, իմաստային որոնումը, պնդում–ապացույց համապատասխանության մոդելը, ժամանակային բաժանումները, նոր աղբյուրների վրա ստուգումը և առանձին հայերեն պիտակավորված տվյալները: Տվյալ փուլում պատրաստ է աղբյուրներով որոնման ու բացատրության տեղային հետազոտական համակարգը: Չեն իրականացվել ցանկացած նոր լուրի վստահելի ինքնաշխատ վերաշարադրում և հայերեն դասակարգիչ: Գործնական մասի նյութերը պատրաստված են նաև Word ձևաչափով:

9 Համակարգի գործարկում և վերարտադրում

Ծրագիրը գտնվում է FakeNewsNet-master պանակի practical ենթապանակում: start.command ֆայլը գործարկելուց հետո միջերեսը հասանելի է http://127.0.0.1:8000 հասցեով, API նկարագրությունը՝ /docs հասցեով: Տեքստի վերլուծությունը կատարվում է /analyze մեթոդով: Առցանց որոնումն անջատված է լռելյայն:

Ուսուցման վերարտադրման համար գործարկվում է python -m fakenews.train հրամանը: Ապացույցների բազան կառուցվում է python -m fakenews.build_evidence, իսկ որոնումը գնահատվում է python -m fakenews.evaluate_evidence հրամանով: Անհրաժեշտ փաթեթների տարբերակները ֆիքսված են requirements.txt ֆայլում:

Պահպանված են տվյալների մաքրման աուդիտը, train/valid/test մանիֆեստը, validation համեմատությունները, թեստային կանխատեսումները, սխալների ցանկը, շփոթության մատրիցները և աղբյուրների SHA-256 հեշերը: Ծրագրային 33 ստուգումներն անցել են: Բրաուզերում ստուգվել են աղբյուրով ուղղումը, փոփոխված պնդման դեպքում ձեռնպահ մնալը, արխիվային արդյունքը և փոքր էկրանի դասավորությունը:

10 Օգտագործված աղբյուրներ

[1] Wang W Y 2017 Liar Liar Pants on Fire A New Benchmark Dataset for Fake News Detection https://aclanthology.org/P17-2067/

[2] Alhindi T Petridis S Muresan S 2018 Where is Your Evidence Improving Fact Checking by Justification Modeling https://aclanthology.org/W18-5513/

[3] FakeNewsNet տվյալների և հավաքման կոդի պաշտոնական պահոց https://github.com/KaiDMML/FakeNewsNet

[4] LIAR-PLUS պաշտոնական պահոց https://github.com/Tariq60/LIAR-PLUS commit 992bfd97555631e48b6bddb1a87aa61c51ee1197

[5] scikit-learn TF-IDF փաստաթղթեր https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

[6] Google Fact Check Tools API որոնման փաստաթղթեր https://developers.google.com/fact-check/tools/api/reference/rest/v1alpha1/claims/search

[7] NASA Sun Facts https://science.nasa.gov/sun/facts/

[8] NASA Earth Facts https://science.nasa.gov/earth/facts/